M2: DATA QUALITY REPORT

Exploratory Data Analysis (KMTI21133) · Bobot 10% · Dikumpulkan pada pertemuan 5

Hapus seluruh teks miring (petunjuk) sebelum mengumpulkan.

Nama tim	Sayu
Anggota dan peran	Aqila Diliansyah Putra — analisis kualitas data dan pemeriksaan nilai kosong; Muhammad Abror — pembersihan data dan penanganan duplikat; Novita — pemeriksaan konsistensi dan validitas; Jul Fikri Hasibuan — penulisan laporan dan dokumentasi; Ghozi — membuat dan menguji notebook Python untuk cleaning.
Judul proyek	Analisis Kualitas Data Prevalensi Stunting Indonesia Tahun 2020–2023
Pertanyaan payung	Bagaimana perkembangan prevalensi stunting di setiap provinsi di Indonesia dari tahun 2020 sampai 2023?
Dataset	Data Stunting Indonesia.csv
Tautan repositori	Belum dicantumkan pada berkas yang diberikan.
Tanggal laporan	19 Oktober 2026

1. Ringkasan

Dataset Data Stunting Indonesia memuat prevalensi stunting untuk 38 provinsi pada tahun 2020–2023. Setelah dibaca menggunakan pemisah titik koma dan koma sebagai tanda desimal, dataset memiliki 38 baris dan 5 kolom yang relevan. Temuan utama adalah satu kolom kosong tambahan akibat titik koma di akhir setiap baris, tidak ditemukan baris duplikat atau nama provinsi duplikat, dan sumber primer/lisensi belum dapat diverifikasi dari berkas yang tersedia. Kolom tambahan yang seluruh nilainya kosong dihapus dari data olahan, sedangkan nilai prevalensi tidak diimputasi atau diubah. Pemeriksaan rentang menemukan seluruh nilai prevalensi berada pada rentang 0–100, tetapi akurasi terhadap sumber resmi belum bisa dipastikan. Dataset layak digunakan untuk analisis eksploratif tren dengan catatan sumber, satuan, dan nilai yang tidak biasa perlu diverifikasi sebelum digunakan untuk kesimpulan kebijakan.

2. Data dan cara memeriksanya

2.1 Asal data

Butir	Isi
Nama sumber	Data Stunting Indonesia (berkas CSV yang diberikan; dataset disebut diperoleh melalui Kaggle pada laporan analisis sebelumnya).
Tautan atau instansi	Kaggle disebut sebagai platform distribusi pada laporan sebelumnya; URL dataset dan sumber primer belum tersedia pada berkas yang diberikan.
Tanggal pengambilan	28 September 2026

Butir	Isi
Lisensi atau nomor izin	https://www.kaggle.com/code/dwiiyy/clustering-data-stunting/input
Kalimat sitasi	Belum dapat dibuat secara lengkap karena nama pengunggah, judul halaman, URL, tanggal publikasi/akses, dan lisensi belum tersedia.

2.2 Ukuran dan cakupan

Data mentah terbaca menjadi 38 baris dan 6 kolom saat CSV dipisahkan dengan sep=";" dan decimal=","; kolom terakhir bernama Unnamed: 5 berisi 38 nilai kosong karena setiap baris diakhiri titik koma. Setelah kolom yang sepenuhnya kosong dihapus, data olahan berukuran 38 baris × 5 kolom. Satu baris mewakili satu provinsi; kolom tahun 2020, 2021, 2022, dan 2023 berisi prevalensi dalam persen. Rentang waktu adalah 2020–2023.

2.3 Cara pemeriksaan

Pemeriksaan dilakukan menggunakan Python dan Pandas: membaca CSV dengan separator dan tanda desimal yang sesuai, memeriksa ukuran dan tipe data, menghitung nilai kosong, memeriksa duplikasi baris serta nama provinsi, menguji rentang nilai prevalensi 0–100, dan menghitung statistik deskriptif sebelum serta sesudah penghapusan kolom kosong. Selain itu, nilai dan ringkasan pada laporan analisis K-Means sebelumnya dibandingkan dengan CSV untuk mendeteksi perbedaan. Pemeriksaan silang terhadap sumber primer resmi dan lisensi belum dapat dilakukan karena tautan/metadata sumber tidak disertakan.

3. Temuan kualitas data

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Kelengkapan	Unnamed: 5	Kolom tambahan seluruhnya kosong akibat pemisah titik koma di akhir baris.	38 sel kosong	Sedang	Hapus kolom karena tidak berisi informasi.
Kelengkapan	Provinsi, 2020–2023	Tidak ada nilai kosong pada lima kolom inti setelah parsing yang benar.	0 sel	Rendah	Pertahankan semua baris; jangan melakukan imputasi.
Keunikan	Seluruh baris	Tidak ditemukan baris duplikat penuh.	0 baris	Rendah	Tidak ada baris yang dihapus atas dasar duplikasi.
Keunikan	Provinsi	Nama provinsi unik; tidak ditemukan nama yang berulang.	38 nilai unik	Rendah	Pertahankan nama provinsi sebagai identitas observasi.
Konsistensi	Format CSV	Delimiter titik koma dan koma desimal harus ditetapkan saat membaca; tanpa parameter tersebut kolom tidak terbaca sesuai maksud.	1 format	Tinggi	Gunakan sep=";", decimal="," dan hapus kolom terakhir yang kosong.
Validitas	2020–2023	Semua nilai prevalensi berada dalam rentang 0–100; tidak ada nilai di luar rentang tersebut.	0 nilai di luar rentang	Sedang	Pertahankan nilai, tetapi verifikasi angka ekstrem dengan sumber primer.
Akurasi	Nilai prevalensi	Akurasi terhadap sumber resmi belum bisa diverifikasi; nilai DKI Jakarta 2020 sebesar 0,1% dan beberapa perubahan besar perlu dikonfirmasi, bukan otomatis dianggap salah.	38 × 4 nilai belum diverifikasi	Sedang	Jangan mengubah angka tanpa sumber pembanding yang sah.
Konsistensi	2022 / Papua	Laporan K-Means sebelumnya	1 perbedaan teridentifikasi	Tinggi	Gunakan CSV sebagai dasar

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
		mencantumkan Papua 2022 = 2,3%, sedangkan CSV menunjukkan 9,1%.			sementara dan koreksi laporan setelah verifikasi sumber.
Konsistensi	Rata-rata 2022	Laporan sebelumnya menulis rata-rata 2022 = 9,64%; perhitungan ulang dari 38 nilai CSV menghasilkan sekitar 9,52%.	1 ringkasan berbeda	Sedang	Hitung ulang ringkasan langsung dari data olahan.

3.1 Pola nilai kosong

Tidak ada kolom inti dengan nilai kosong di atas 5%. Kolom tambahan Unnamed: 5 memiliki 100% nilai kosong (38 dari 38 baris), tetapi bentuknya menunjukkan kolom artefak dari delimiter akhir, bukan variabel substantif. Karena penyebabnya tampak berasal dari format file, kolom tersebut dihapus; dugaan MCAR/MAR/MNAR tidak diterapkan pada kolom artefak ini.

Kolom	Persen kosong	Dugaan	Dasar dugaan
Unnamed: 5	100% (38/38)	Artefak format	Setiap baris CSV memiliki titik koma penutup; kolom tidak mengandung informasi dan seluruh nilainya kosong.
—	—	—	—
—	—	—	—
—	—	—	—
—	—	—	—

4. Keputusan pembersihan dan alasannya

Masalah	File CSV menggunakan tanda titik koma (`;`) sebagai pemisah kolom dan koma (`,`) sebagai tanda desimal, tetapi pembacaan awal tidak menggunakan parameter yang sesuai sehingga seluruh data terbaca sebagai satu kolom.
Dugaan pola	Masalah konsistensi format dan struktur data, bukan nilai yang hilang secara langsung.
Keputusan	Membaca ulang CSV menggunakan `pd.read_csv(data, sep=';', decimal=',')`, kemudian memeriksa dan menangani kolom kosong tambahan di akhir jika memang ada.
Alasan	Pemisah kolom dan desimal harus dibaca dengan benar agar nama provinsi dan nilai prevalensi tahun 2020–2023 dapat dianalisis secara terpisah.
Alternatif ditolak	Mempertahankan hasil pembacaan awal ditolak karena data hanya terbaca sebagai satu kolom sehingga analisis per provinsi dan per tahun tidak dapat dilakukan dengan benar.
Dampak	Struktur data menjadi sesuai untuk pemeriksaan nilai kosong, duplikasi, validitas angka prevalensi, dan analisis perkembangan stunting tahun 2020–2023.

Keputusan tim Anda

Keputusan 1

Masalah	Kolom tambahan Unnamed: 5 seluruhnya kosong.
Dugaan pola	Tidak berlaku sebagai MCAR/MAR/MNAR; pola konsisten dengan artefak format.
Keputusan	Hapus kolom kosong dari data olahan; simpan berkas mentah tanpa perubahan.
Alasan	Kolom tidak memberi informasi dan menambah 38 sel kosong palsu pada pemeriksaan kualitas.
Alternatif ditolak	Mempertahankan kolom ditolak karena dapat membuat pembaca mengira ada variabel yang hilang.
Dampak	Jumlah kolom turun dari 6 menjadi 5; 38 sel kosong hilang; baris tetap 38.

Keputusan 2

Masalah	File memakai titik koma sebagai pemisah dan koma sebagai tanda desimal.
Dugaan pola	Masalah format, bukan missingness.
Keputusan	Baca dengan pd.read_csv(..., sep=";", decimal=",").
Alasan	Pembacaan default berisiko menggabungkan data menjadi satu kolom dan membuat analisis tidak valid.
Alternatif ditolak	Mengganti delimiter secara manual pada file mentah ditolak agar sumber asli tidak berubah.
Dampak	Kolom Provinsi dan empat kolom tahun terbaca terpisah dengan tipe data numerik.

Keputusan 3

Masalah	Tidak ditemukan duplikasi baris maupun nama provinsi.
Dugaan pola	Tidak ada indikasi duplikasi pada pemeriksaan ini.
Keputusan	Pertahankan seluruh 38 baris.
Alasan	Menghapus baris tanpa duplikasi akan mengurangi cakupan provinsi secara tidak beralasan.
Alternatif ditolak	Menghapus baris berdasarkan dugaan kemiripan nilai ditolak karena prevalensi berbeda antartahun adalah informasi penting.
Dampak	Jumlah baris tetap 38; 38 nama provinsi tetap unik.

Keputusan 4

Masalah	Nilai prevalensi perlu diuji terhadap batas wajar dan sumber primer.
Dugaan pola	Tidak dapat menyimpulkan pola missingness; tidak ada nilai kosong pada kolom inti.
Keputusan	Validasi rentang 0–100; jangan mengubah nilai yang berada dalam rentang sebelum ada sumber pembanding.
Alasan	Rentang 0–100 sesuai interpretasi persen, tetapi rentang saja tidak membuktikan akurasi.
Alternatif ditolak	Menghapus nilai ekstrem atau menggantinya dengan rata-rata ditolak karena dapat mengubah tren secara artifisial.
Dampak	Semua 152 nilai tahunan tetap; akurasi eksternal tetap menjadi keterbatasan.

Keputusan 5

Masalah	Terdapat ketidaksesuaian antara CSV dan laporan K-Means sebelumnya untuk Papua 2022 serta rata-rata 2022.
Dugaan pola	Bukan missingness; ketidaksesuaian ada pada dokumentasi/hasil hitung.
Keputusan	Hitung ulang ringkasan dari CSV dan tandai angka laporan lama untuk diperiksa.
Alasan	Satu sumber data yang konsisten harus menjadi dasar angka laporan; CSV menunjukkan Papua 2022 = 9,1% dan rata-rata tahun 2022 sekitar 9,52%.
Alternatif ditolak	Memilih angka dari laporan lama tanpa menghitung ulang ditolak karena tidak cocok dengan 38 nilai CSV.
Dampak	Hasil ringkasan yang dipakai di laporan M2 diselaraskan dengan CSV; nilai sumber tetap menunggu verifikasi resmi.

5. Dampak pembersihan terhadap data

5.1 Sebelum dan sesudah

Ukuran	Sebelum	Sesudah	Catatan
Jumlah baris	38	38	Tidak ada baris dihapus.
Jumlah kolom	6	5	Satu kolom tambahan seluruhnya kosong dihapus.
Total sel kosong	38	0	Semua 38 nilai kosong berada di kolom Unnamed: 5.
Baris duplikat	0	0	Tidak ada duplikasi baris penuh.
Jumlah kategori pada kolom kunci	38	38	Kolom Provinsi berisi 38 nama berbeda.
Nilai unik pada kolom identitas	38	38	Setiap nama provinsi unik.

5.2 Dampak terhadap sebaran

Kolom	Mean sebelum	Mean sesudah	Pergeseran	Penilaian
2020	2020: mean 12.13, median 11.40, SD 6.96	2020: mean 12.13, median 11.40, SD 6.96	0,00	Tidak bergeser; hanya kolom kosong dihapus.
2021	2021: mean 10.56, median 10.40, SD 5.32	2021: mean 10.56, median 10.40, SD 5.32	0,00	Tidak bergeser; hanya kolom kosong dihapus.
2022 dan 2023	2022: mean 9.52, median 9.25, SD 5.41; 2023: mean 7.87, median 7.25, SD 4.93	2022: mean 9.52, median 9.25, SD 5.41; 2023: mean 7.87, median 7.25, SD 4.93	0,00	Tidak bergeser; hanya kolom kosong dihapus.

6. Keterbatasan

Data tidak memungkinkan pemulihan metadata sumber yang tidak disertakan. Akibatnya, akurasi angka terhadap sumber resmi, definisi operasional prevalensi, metode pengumpulan, dan keterbandingan antartahun belum dapat dipastikan.

- Kolom yang tidak dapat dipulihkan: URL sumber, nama pengunggah, tanggal publikasi/pengambilan, lisensi, serta metadata metodologi. Hal ini membatasi verifikasi angka prevalensi dan interpretasi tren antarprovinsi.
- Tidak ada kolom inti yang kosong sehingga dugaan MNAR tidak diperlukan untuk nilai prevalensi. Namun, tanpa metadata proses pengumpulan, kemungkinan bias pelaporan atau perubahan metode antartahun tidak dapat dinilai; arah biasnya tidak dapat ditentukan dari CSV saja.
- Pemeriksaan silang ke BPS/Kementerian Kesehatan atau sumber primer, validasi definisi prevalensi, lisensi, serta metode survei belum dilakukan karena tautan dan metadata sumber tidak tersedia.
- Diasumsikan setiap baris mewakili satu provinsi dan nilai tahun merupakan prevalensi dalam persen. Perlu konfirmasi apakah angka benar-benar dapat dibandingkan langsung antar tahun dan apakah cakupan 38 provinsi sudah konsisten untuk periode 2020–2023.

7. Penanganan data pribadi

Butir	Keterangan
Kolom data pribadi pada data olahan	Tidak ada; hanya nama provinsi dan angka prevalensi agregat.
Tindakan penanganan yang diterapkan	Tidak ada data individu yang perlu disamarkan. Data mentah dipertahankan dan kolom artefak dihapus hanya pada salinan olahan.
Nilai k pada data yang diunggah	Tidak berlaku; tidak terdapat catatan individu atau pengenal pribadi.
Status repositori (publik atau privat)	Belum diketahui; tautan repositori belum diberikan.
data/raw/ masuk .gitignore	Belum dapat diverifikasi. Jika repositori digunakan, simpan CSV asli di data/raw/ dan tambahkan direktori tersebut ke .gitignore sesuai instruksi tugas.

8. Langkah berikutnya

1. Verifikasi URL, pemilik dataset, lisensi, dan sumber primer yang tercantum pada halaman Kaggle.
2. Bandingkan nilai tahunan dengan sumber resmi dan dokumentasikan setiap koreksi beserta rujukannya.
3. Jalankan notebook EDA dari awal sampai akhir dengan file CSV yang sudah dibaca menggunakan delimiter yang benar.
4. Perbarui grafik tren dan ringkasan statistik berdasarkan data olahan yang tervalidasi.

5. Konfirmasi definisi prevalensi, metode pengumpulan, dan keterbandingan antar tahun kepada dosen/pemilik data.

Lampiran A — Cleaning log

#	Langkah	Baris terdampak	Alasan
1	Membaca CSV dengan sep=";" dan decimal=","	38 baris	Membuat kolom provinsi dan tahun terbaca sesuai struktur aslinya.
2	Mengidentifikasi kolom Unnamed: 5	38 sel	Seluruh kolom kosong berasal dari titik koma penutup pada setiap baris.
3	Menghapus kolom yang seluruh nilainya kosong pada salinan olahan	38 sel kosong; 1 kolom	Kolom tidak berisi informasi dan tidak dipertahankan untuk analisis.
4	Memeriksa duplikasi baris	0 baris dihapus	Tidak ditemukan baris duplikat penuh.
5	Memeriksa keunikan nama provinsi	38 nama unik	Tidak ditemukan nama provinsi yang berulang.
6	Memeriksa rentang nilai prevalensi	152 nilai diperiksa	Seluruh nilai berada dalam rentang 0–100.
7	Menghitung ulang statistik tahun 2020–2023	4 kolom numerik	Memastikan ringkasan laporan konsisten dengan CSV.
8	Mencatat ketidaksesuaian CSV dan laporan terdahulu	2 perbedaan ringkasan	Papua 2022 dan rata-rata 2022 perlu diselaraskan dengan hitungan dari CSV dan diverifikasi ke sumber primer.

Lampiran B — Peta keputusan manual

Nilai asal	Diubah menjadi	Dasar keputusan
CSV dengan titik koma dan koma desimal	Dibaca dengan sep=";", decimal=","	Berdasarkan pola pemisah yang terlihat konsisten pada isi file.
Kolom Unnamed: 5	Dihapus dari salinan olahan	Seluruh 38 nilai kosong dan tidak ada informasi yang dapat dipulihkan dari kolom tersebut.
Nama provinsi	Dipertahankan sesuai ejaan pada CSV	Tidak dilakukan normalisasi nama karena 38 nama sudah unik; perubahan harus didukung sumber resmi.
Papua tahun 2022 pada laporan lama: 2,3%	Tandai untuk diperiksa; CSV memuat 9,1%	Nilai CSV dibaca langsung dari baris PAPUA; perlu pembandingan dengan sumber primer sebelum final.
Rata-rata 2022 pada laporan lama: 9,64%	Hitung ulang menjadi 9,52% dari CSV	Rata-rata aritmetika 38 nilai pada kolom 2022; perlu memperbarui dokumen terdahulu.
URL/lisensi sumber tidak tersedia	Tidak diisi dengan tebakan	Informasi tidak terdapat pada berkas yang diberikan; perlu mengambil dari halaman dataset.

Daftar periksa sebelum mengumpulkan

- ✓ Teks petunjuk diganti dengan isi laporan; struktur template dipertahankan.
- ✓ Temuan utama pada Bagian 3 memiliki keputusan yang sesuai pada Bagian 4.
- ✓ Keputusan 1–5 mencantumkan alternatif yang ditolak.
- ✓ Statistik mean, median, dan simpangan baku sebelum/sesudah dicantumkan.
- ✓ Keterbatasan dijelaskan pada Bagian 6.
- Belum diverifikasi: notebook harus dijalankan Restart and run all sebelum pengumpulan.
- Belum diverifikasi: pastikan cleaning_log.md tersedia di akar repositori.
- Belum diverifikasi: pastikan data/raw/ tidak diubah dan tidak diunggah ke repositori.
- Belum dijalankan: python cek_m2.py harus diuji sebelum pengumpulan.